



UNIVERSIDAD
DE MURCIA




TRABAJO FIN DE MÁSTER

Máster en Bioinformática

Facultad de Biología – Universidad de Murcia

PhageTax: una herramienta bioinformática para la clasificación taxonómica de bacteriófagos



PhageTax

Autora: Marina García Cervera

Curso 2024/2025

Índice de contenidos

Resumen.....	1
1. Introducción.....	2
1.1. ¿Qué son los bacteriófagos?.....	2
1.2. El desafío de la clasificación taxonómica de bacteriófagos.....	2
1.3. Herramientas bioinformáticas para el análisis de fagos.....	3
1.4. ¿Qué son los PHROG?.....	3
1.5. Métodos bioinformáticos para la clasificación taxonómica de fagos.....	4
2. Objetivos.....	5
3. Materiales y métodos.....	5
3.1. Descripción general del flujo de trabajo.....	5
3.2. Generación del <i>dataset</i> utilizado en los procesos de ML.....	6
3.2.1. Datos de entrada: selección de genomas de fagos.....	6
3.2.2. Anotación funcional de los genomas virales.....	6
3.2.3. Preprocesamiento y filtrado.....	7
3.2.4. Generación y análisis del <i>dataset</i> final.....	7
3.2.5. Análisis de la frecuencia de PRHOG por nivel taxonómico.....	9
3.2.6. Identificación de PHROG característicos y específicos.....	9
3.2.7. Relación entre el número de PHROG y características genómicas.....	9
3.3. Desarrollo del modelo multinivel taxonómico.....	10
3.3.1. Datos de entrada y procesamiento.....	10
3.3.2. Entrenamiento del modelo.....	10
3.3.3. Evaluación y métricas obtenidas a partir del modelo.....	11
3.4. Desarrollo de los modelos de ML para cada nivel taxonómico.....	11
3.5. Diferencias entre los modelos de ML implementados.....	12
4. Resultados y discusión.....	12
4.1. <i>PhageTax</i>	12
4.2. Construcción y análisis del <i>dataset</i>	13
4.3. Análisis del modelo predictivo multinivel para la clasificación taxonómica.....	14
4.3.1. Evaluación del modelo multinivel.....	14
4.3.2. Relación entre el número de genomas en un género y el rendimiento del modelo.....	15
4.3.3. Relación entre el número de PHROG de un género y el rendimiento del modelo.....	16
4.4. Evaluación de los modelos específicos para los niveles taxonómicos.....	17
4.5. Resultados para una selección de genomas virales de clasificación conocida.....	20
4.6. Aplicabilidad y perspectivas futuras.....	21
5. Conclusiones.....	21
6. Relación del trabajo con los Objetivos de Desarrollo Sostenible.....	22
7. Bibliografía.....	22
8. Anexos.....	25
8.1. Selección de herramientas existentes para el análisis.....	25
8.2. Infografía de la herramienta <i>PhageTax</i>	26

Resumen

Los bacteriófagos, virus que infectan a bacterias, desempeñan un papel fundamental en los ecosistemas microbianos y su estudio es clave para el desarrollo de terapias alternativas frente a la creciente amenaza de las bacterias multirresistentes. Sin embargo, la enorme diversidad de fagos y la ausencia de genes universales de referencia dificultan su clasificación taxonómica. A pesar de los avances recientes, las herramientas actuales para la clasificación taxonómica de bacteriófagos siguen ofreciendo resultados poco precisos, en su aplicación a genomas nuevos o poco estudiados.

Partiendo de la hipótesis de que es posible desarrollar un sistema de clasificación taxonómica automático a partir de características genómicas, funcionales y taxonómicas, se ha desarrollado *PhageTax*, una herramienta bioinformática de código abierto diseñada para predecir la taxonomía de bacteriófagos a partir de sus secuencias genómicas. *PhageTax* emplea como predictores clave los PHROG (*Prokaryotic Virus Remote Homologous Groups*) e integra algoritmos de *Machine Learning* concretamente *Random Forest*, para predecir seis niveles taxonómicos, desde Reino hasta Especie. Durante el desarrollo, se generaron distintos modelos *Random Forest* independientes para cada nivel taxonómico, evaluando diversas estrategias de ponderación de variables y ajuste de clases desbalanceadas. Entre los predictores incluidos, se incorporó también la presencia de PHROG específicos para reforzar la discriminación en niveles como género y especie. Además, se implementó un sistema de avisos que informa sobre la fiabilidad de las predicciones.

Los resultados obtenidos con el modelo final muestran una alta precisión en los niveles taxonómicos superiores y un rendimiento destacable en niveles específicos, como género y especie, incluso en presencia de clases poco representadas. En conjunto, *PhageTax* representa un avance hacia la estandarización y automatización de la clasificación taxonómica de bacteriófagos, siendo la primera herramienta que aplica algoritmos de *Machine Learning* con este objetivo.

Abstract

Bacteriophages, viruses that infect bacteria, play a fundamental role in microbial ecosystems and are considered key players in the development of alternative therapies against the growing threat of multidrug-resistant bacteria. However, the vast diversity of phages and the absence of universal marker genes greatly hinder their taxonomic classification. Despite recent advances, current tools for the taxonomic classification of bacteriophages still present significant limitations, in their application to novel or poorly studied genomes.

Based on the hypothesis that an automatic classification system can be developed using genomic, functional, and taxonomic features, we present *PhageTax*, an open-source bioinformatics tool designed to predict the taxonomy of bacteriophages from their genomic sequences. *PhageTax* leverages PHROG (Prokaryotic Virus Remote Homologous Groups) as key predictive features and integrates machine learning algorithms, specifically Random Forest, to assign taxonomy across six hierarchical levels, from kingdom to species. Independent Random Forest models were trained for each taxonomic level, exploring different strategies for feature weighting and handling class imbalance. Additionally, the presence of taxon-specific PHROG was incorporated to improve classification performance at the lower levels such as genus and species. A warning system was also implemented to inform users about the reliability of predictions.

The final model demonstrated high accuracy at higher taxonomic ranks and significant performance at the genus and species levels, even when dealing with underrepresented classes. Altogether, *PhageTax* represents a step forward in the standardization and automation of phage taxonomy, being the first tool to apply machine learning methods for full-rank taxonomic prediction of bacteriophages.

1. Introducción

1.1. ¿Qué son los bacteriófagos?

Los bacteriófagos, también conocidos como fagos, son los virus capaces de infectar a bacterias. Están presentes en todos los ecosistemas conocidos, desempeñando un importante papel en la interacción y evolución microbiana. Su abundancia en la Tierra supera incluso a la de las propias células procariotas, como se ha observado en hábitats extremos y poco explorados como el subsuelo oceánico, donde las partículas víricas pueden superar a las células bacterianas por un factor de hasta 9 veces (Nigro et al., 2017). El estudio de bacteriófagos ha sido fundamental en el desarrollo de la Biología Molecular (Salmond & Fineran, 2015). Recientemente, los campos de estudio de los bacteriófagos han tenido un gran desarrollo. Un ejemplo de ello es la fagoterapia (terapia con fagos). Esta nueva línea de trabajo ha surgido como una alternativa frente a la creciente amenaza de las bacterias multirresistentes a antibióticos. Su eficacia clínica se ha demostrado en numerosas ocasiones. Por ejemplo, una serie de ensayos llevados a cabo en Polonia con más de 500 pacientes demostraron una tasa de recuperación del 94% en infecciones que no habían respondido previamente al tratamiento con antibióticos (Sulakvelidze et al., 2001). Asimismo, su aplicación no sólo se ha centrado en la salud humana, sino que se han extendido a otros campos como la acuicultura. Tanto es así, que desde hace unos años las publicaciones sobre el aislamiento y caracterización de bacteriófagos aislados de muestras procedentes de ambientes donde ha habido infección bacteriana han ido creciendo y las primeras aproximaciones experimentales al uso de fagoterapia en peces son recientes (Ronda et al., 2003).

1.2. El desafío de la clasificación taxonómica de bacteriófagos

La cantidad de virus conocidos está aumentando rápidamente y con toda seguridad quedan muchos más virus aún no descubiertos, lo que añade dificultad a su clasificación (Caetano-Anollés et al., 2023). Sin embargo, la clasificación taxonómica de los bacteriófagos sigue siendo un reto en la actualidad. Caetano-Anollés et al. (2023) señalan que uno de los mayores problemas de la taxonomía viral es que se ha intentado clasificar a los virus antes de comprender completamente su origen y su evolución. Históricamente, los fagos fueron en primer lugar clasificados según su morfología. Para los fagos con cola, la taxonomía se derivó del trabajo pionero de clasificación de Bradley (1967b), quien los clasificó en tres morfotipos: A (cola contráctil), B (cola larga no contráctil), C (cola corta no contráctil), basándose en microscopía electrónica (figura 1), un sistema que posteriormente fue perfeccionado por Ackermann y Eisenstark (1974). En 1971, este sistema fue adoptado formalmente por el Comité Internacional de Taxonomía de Virus (ICTV), disponible en <https://ictv.global/>.




Figura 1. Imagen de Bradley (1967b) de la cabeza del colifago T4 observada a la izquierda mediante microscopía electrónica con tinción negativa en uranil-formiato (barra de escala: 1000 Å); al centro y derecha, representaciones esquemáticas de la geometría icosaédrica de la cápside.

El desarrollo de métodos moleculares como la secuenciación genómica ha hecho que este sistema de clasificación quede obsoleto. Actualmente, los virus se clasifican en taxones que se colocan en niveles jerárquicos, que se denominan Dominio, Reino, Filo, Clase, Orden, Familia, Género y Especie. Se han abolido las familias basadas en la morfología: *Podoviridae* (cola corta no contráctil) *Myoviridae*, (cola larga no contráctil) y *Siphoviridae* (cola larga no contráctil), así

como el orden *Caudovirales*, que se ha sustituido por la clase *Caudoviricetes*, para agrupar a todos los virus bacterianos y de arqueas con cola, cápsides icosaédricas y genomas de ADN de doble cadena. Este cambio fue necesario debido a múltiples evaluaciones independientes que demostraron que estas familias basadas en la morfología son polifiléticas y no reflejan con precisión las historias evolutivas compartidas (Turner et al., 2023). Esta taxonomía de 15 niveles (contando estos 9 principales y sus subcategorías) está diseñada para abarcar todo el espectro de diversidad genética y relaciones evolutivas y recuerda al sistema taxonómico linneano de los organismos celulares. El principio de la taxonomía viral actual es que las asignaciones taxonómicas deben ser congruentes con las historias evolutivas de los virus; es decir, los taxones deben ser monofiléticos, aunque con la salvedad de que algunos genomas virales pueden tener historias evolutivas complejas (Siddell et al., 2023). La dificultad en el análisis de la historia evolutiva de los virus se debe, en gran medida, a la ausencia de un gen marcador universal en los virus, análogo al gen 16S rRNA en bacterias, ya que dificulta el establecimiento de marcos filogenéticos sólidos para estos (Turner et al., 2023).

La gran diversidad de virus que se están detectando, tanto mediante aislamiento de nuevos virus como mediante estudios metagenómicos, se está recogiendo en bases de datos, que también están jugando un gran papel en facilitar la clasificación taxonómica de los fagos. Un ejemplo es el *Virus Metadata Resource* (VMR) (Siddell et al., 2023), disponible en <https://ictv.global/vmr>, que proporciona información sobre al menos un virus asignado a cada especie, incluyendo el nombre del virus, un número de acceso para todo o parte de su genoma, la naturaleza de su genoma (ADN o ARN, monocatenario o bicatenario, de sentido positivo o negativo), la clasificación taxonómica completa y el hospedador natural (planta, animal, hongo, protista, bacteria o arquea), si se conoce. Esto permite, al buscar en el VMR, vincular nombres de virus con la especie a la que pertenece y los taxones superiores correspondientes, así como vincular la especie de un virus con la secuencia genómica de un virus tipo.

1.3. Herramientas bioinformáticas para el análisis de fagos

Existe una gran variedad de herramientas bioinformáticas de código abierto destinadas al estudio de los bacteriófagos (ver apartado Anexos, subapartado 7.1). Algunas de ellas, como *VirSorter* (Roux et al., 2015) o *VIBRANT* (Kieft et al., 2020), están diseñadas para la anotación funcional de genes virales a partir de conjuntos de metadatos genómicos. Otras herramientas están enfocadas en la construcción de árboles filogenéticos. Esto puede ser más útil para conseguir una aproximación a la clasificación taxonómica de estos virus. Un ejemplo de ello es *VICTOR* (Meier-Kolthoff & Göker, 2017), una herramienta que permite deducir relaciones filogenéticas a partir de genomas completos, mediante el cálculo de distancias y la generación de árboles. En cambio, *ViPTree* (Nishimura et al., 2017) se basa en similitudes en el proteoma. Esta herramienta también genera árboles que ayudan a la clasificación de los virus y a explorar su diversidad de forma visual.

A pesar de la gran variedad de estas herramientas, su utilidad presenta algunas limitaciones. Las herramientas de anotación de los genomas virales, por ejemplo, no aportan información taxonómica. Esto obliga al investigador a hacer análisis adicionales. Por otro lado, las herramientas de construcción de árboles filogenéticos, como *VICTOR* y *ViPTree*, muestran los virus en base a su similitud genómica o proteómica con otros virus. Sin embargo, estas herramientas no están directamente respaldadas por bases de datos taxonómicas oficiales, como el VMR del ICTV, ni aportan la clasificación taxonómica. Por tanto, si bien su uso puede servir de aproximación, no deja de ser una guía poco fiable.

1.4. ¿Qué son los PHROG?

Los PHROG (*Prokaryotic Virus Remote Homologous Groups*) son una librería de familias de proteínas virales generada utilizando un nuevo enfoque de agrupamiento basado en la detección de homologías remotas mediante comparaciones de Modelos Ocultos de Markov (figura 2). La base de datos de PHROG contiene 38.880 de ellos, que incluyen 868.340 proteínas de 17.473 genomas completos de virus que infectan microorganismos como bacterias y arqueas (Bouras et al., 2022). Una de las utilidades de los PHROG es su aplicación en la anotación de genomas virales y así lo demuestran Bouras et al. (2022) al emplearlos en su herramienta *Pharokka*. *Pharokka* permite anotar genomas de bacteriófagos funcionalmente de manera fácil y rápida.

Para ello, hace uso de la herramienta MMseqs2 (Steinegger & Söding, 2017) para la comparación de las proteínas de los fagos a analizar con los PHROG. De esta forma asigna a cada gen viral la anotación correspondiente con el gen homólogo que se pueda encontrar en esta base de datos.




Figura 2. Extracto del esquema del proceso de agrupamiento de proteínas virales en PHROG (Terzian et al., 2021). A partir de similitudes entre proteínas (1), se generan clústeres iniciales (2), que se agrupan (3) hasta formar los PHROG, supergrupos de proteínas homólogas (4).

1.5. Métodos bioinformáticos para la clasificación taxonómica de fagos

En los últimos años se han desarrollado herramientas bioinformáticas con el fin de facilitar la clasificación taxonómica de fagos mediante diversas aproximaciones computacionales. Entre los enfoques más clásicos destaca *ClaseiPhage* (Chibani et al., 2019). Chibani desarrolló esta herramienta para la clasificación taxonómica de fagos mediante la detección de genes utilizando modelos ocultos de Markov o HMM (Eddy, 1998) y redes neuronales artificiales o ANN (LeCun et al., 2015). Sin embargo, su aplicabilidad se ve limitada por la necesidad de tener los genomas virales bien anotados y su escasa capacidad de escalado. *taxmyPHAGE* (Millard et al., 2024) es otro ejemplo de herramientas que permiten obtener una aproximación taxonómica de fagos a partir del cálculo de la similitud genómica mediante ANI (*Average Nucleotide Identity*). Además, para ello sigue los parámetros recomendados por el ICTV para distintos niveles taxonómicos (Familia, Género, Especie...).

Otros métodos, como los usados en el desarrollo de la herramienta *vConTACT* (Bolduc et al., 2017), se centran en el análisis de redes de genes compartidas entre los virus. Si bien de esta forma se puede agrupar genomas de forma eficiente, su rendimiento se ve mermado al trabajar con fragmentos genómicos o secuencias incompletas. *PhaGCN* (Shang et al., 2021) es otra herramienta que sí es capaz de manejar fragmentos cortos y *contigs* con elevada precisión a partir de un modelo semisupervisado en el que se emplean redes neuronales convolucionales o CNN (LeCun et al., 2015). Recientemente, la tendencia está siendo estudiar el potencial del *Machine Learning* o ML (Mitchell, 1997) en este ámbito. Ejemplos de ello son las herramientas *PhageScanner* (Albin et al., 2024) y *PhageDPO* (Vieira et al., 2025). Ambas se centran de forma exclusiva en la predicción de moléculas específicas codificados por fagos, como las depolimerasas o DPOs y proteínas de virión o PVPs.

A pesar de los intentos avanzar en la clasificación taxonómica de fagos, actualmente no existe una herramienta capaz de realizar una predicción taxonómica mediante algoritmos de ML, utilizando características genómicas y siguiendo los criterios taxonómicos oficiales establecidos por el ICTV. Esto pone de manifiesto la necesidad de desarrollar nuevas estrategias computacionales que integren de manera eficiente esta información.

Con el fin de superar esta limitación, se plantea la hipótesis de que es posible construir un modelo de *machine learning* robusto, basado en la presencia/ausencia de PHROG, que prediga con precisión la taxonomía de un fago a diferentes niveles. Esta hipótesis orienta el desarrollo y evaluación de una herramienta bioinformática diseñada específicamente para este fin.

2. Objetivos

El objetivo principal de este trabajo es el desarrollo una herramienta bioinformática de código abierto para la clasificación taxonómica automática de bacteriófagos a partir de sus secuencias genómicas y la presencia/ausencia de PHROG, incorporando técnicas de ML que permitan facilitar y estandarizar este proceso para el investigador. Este objetivo general se desglosa en los siguientes objetivos particulares:

- Construir una base de datos curada que integre los genomas de bacteriófagos representativos junto con su clasificación taxonómica oficial (según el ICTV) y los grupos PHROG presentes en cada genoma.
- Desarrollar un modelo supervisado de ML capaz de predecir de forma automática y fiable a cuáles de los diferentes niveles taxonómicos pertenecen los bacteriófagos a analizar a partir de sus características genómicas y PHROG detectados.
- Generar salidas con soporte suficiente por parte del modelo, que permitan al investigador no sólo obtener una predicción taxonómica, sino también comprender el nivel de confianza y los elementos genómicos que han contribuido a dicha predicción.
- Evaluar de forma rigurosa el rendimiento del modelo mediante métricas estándar y análisis comparativos.
- Publicar la herramienta como software de código abierto, facilitando su uso por parte de la comunidad investigadora.

3. Materiales y métodos

3.1. Descripción general del flujo de trabajo

Con el fin de elaborar una herramienta bioinformática capaz de clasificar taxonómicamente bacteriófagos a partir de su información genómica se ha diseñado un flujo de trabajo bioinformático estructurado en varias etapas. La figura 3 resume gráficamente el proceso de trabajo.




Figura 3. Esquema general del flujo de trabajo definido para la predicción taxonómica. (A) Se parte de una selección inicial de genomas de fagos a partir del recurso *Virus Metadata Resource* (VMR), priorizando aquellos con clasificación oficial según el ICTV y buena calidad genómica. (B) Para los genomas seleccionados, se procede a la descarga de archivos FASTA que contienen las secuencias genómicas completas. (C) Estos archivos se someten a anotación funcional mediante *Pharokka*, lo que permite identificar los PHROG y extraer información genómica relevante. (D) A continuación, se realiza un preprocesamiento y filtrado de los resultados para integrar tres tipos de información: presencia/ausencia de PHROG, características genómicas y taxonomía. (E) Esta información se estructura en un *dataset* final. (F) Se lleva a cabo un análisis funcional, que incluye el cálculo de frecuencia de cada PHROG por nivel taxonómico, la identificación de PHROG característicos y específicos. (G) A partir del *dataset* resultante, se entrena un modelo de ML para predecir la taxonomía de nuevos fagos. (H) Finalmente, la herramienta permite realizar una predicción taxonómica automática de nuevos genomas de fagos basándose en sus características funcionales. Realización propia en *Canva* (<https://www.canva.com/>).

3.2. Generación del *dataset* utilizado en los procesos de ML

La creación del *dataset* se dividió en varias etapas.

3.2.1. Datos de entrada: selección de genomas de fagos

La recopilación de datos para la construcción del *dataset* de partida se ha llevado a cabo a partir de dos bases de datos oficiales y públicas, como VMR y la tabla de PHROG (ver Materiales y métodos, subapartado 3.1.4. Generación y análisis del *dataset*).

VMR es una base de datos elaborada y mantenida por el ICTV. En ella se proporciona información taxonómica relevante como el nombre del virus, su genoma de referencia y el hospedador natural, entre otros datos. Esta base de datos es de libre acceso y se puede descargar en formato .xlsx. El archivo utilizado en este trabajo es el *VMR_MSL40.v1.20250307.xlsx*, que es la versión más reciente, del 7 marzo de 2025. Además, este estaba compuesto por varias hojas:

- En *version* aparecía información relativa a la versión del archivo, así como el nombre de su editor (Donald Smith).
- VMR MSL40 es la hoja principal, donde se almacenan los datos de los virus.
- En *Column definitions* se explica cada columna del archivo.

Dentro de la hoja VMR MSL40 se encuentran 28 columnas y 17.918 filas. Entre los campos incluidos en las columnas aparecían los distintos niveles taxonómicos oficiales: Dominio, Subdominio, Reino, Subreino, Filo, Subfilo, Clase, Subclase, Orden, Suborden, Familia, Subfamilia, Género, Subgénero y Especie. También cabe destacar las columnas *Virus GENBANK accession* y *Accessions Link*. GenBank® (<http://www.ncbi.nlm.nih.gov>) es una base de datos integral que contiene secuencias de nucleótidos de acceso público para casi 260.000 especies de diferentes niveles taxonómicos (Benson et al., 2012). Su código de acceso es un identificador único asignado por esta base de datos a la secuencia genómica del organismo, de forma que se puede consultar y descargar desde la página web del Centro Nacional de Información Biotecnológica (NCBI).

Tras revisar el archivo obtenido de la base de datos VMR, se definió la información relevante para la posterior construcción del *dataset* de la herramienta *PhageTax*: los genomas completos en formato FASTA de aquellos virus (fagos) que infectaban específicamente bacterias.

3.2.2 Anotación funcional de los genomas virales

Para la anotación funcional de los genomas virales se ha utilizado la herramienta *Pharokka* diseñada por Bouras et al. (2022) para la anotación rápida de bacteriófagos.

Además de la base de datos de los PHROG, *Pharokka* incorpora detección de factores de virulencia y genes de resistencia antimicrobiana usando la *Comprehensive Antibiotic Resistance Database* (CARD) de Alcock et al. (2022) y la *Virulence Factor Database* (VFDB) de Chen et al. (2004). También utiliza *PHANOTATE* (McNair et al., 2019) por defecto para predecir CDS y *Prodigal* (Hyatt et al., 2010), un predictor de genes diseñado para genes procariotas. Además, *Pharokka* emplea tRNAscan-SE 2 (Chan & Lowe, 2019) para predecir tRNAs, *Aragorn* (Laslett, 2004) para predecir tmRNAs y MinCED (Bland et al., 2007) para detectar CRISPRs. Todas las CDS predichas se traducen a proteínas y se asignan a la proteína más similar y al PHROG correspondiente en la base de datos de los PHROG mediante la herramienta de búsqueda de proteínas MMseqs2 (Steinegger & Söding, 2017).

Para la ejecución de la herramienta *Pharokka* se desarrolló un sistema que permitía ejecutar la herramienta mediante el uso de *scripts* en *Bash* y el gestor de colas SLURM del servidor, más concretamente en la partición *eck-q* (figura 4). En primer lugar, se dividieron los genomas a anotar en 30 bloques, generando archivos de texto donde se almacenaron los genomas descargados anteriormente nombrados por sus identificadores (*Virus GENBANK accession*) y sin la extensión

FASTA (genomas_parte_00.txt ... genomas_parte_29.txt). Esto se consiguió empleando el comando *split* de GNU/Linux.

Para procesar cada bloque de genomas con *Pharokka*, se creó el *script anotar_bloque.sh*, que recibía como argumentos los archivos TXT ya mencionados. Este *script* iteró sobre los identificadores de los genomas listados en dichos archivos y, para cada uno, se verificó si los principales archivos de salida de *Pharokka* ya estaban presentes. En caso afirmativo, se omitía la anotación para evitar duplicidades. En caso contrario, se ejecutaba *Pharokka* sobre el genoma correspondiente, indicando explícitamente las rutas al archivo FASTA, la carpeta de salida y las bases de datos. Además, el *script* se diseñó para que fuera capaz de gestionar los casos en los que el archivo FASTA no estuviera disponible en la carpeta, mostrando un aviso sin interrumpir el resto del proceso.

La ejecución de cada bloque se gestionó en el clúster mediante el *script anotar_bloque.sbatch*, con el que se definieron los recursos de cómputo necesarios (memoria, número de hilos y cola de ejecución) y se activaba el entorno previamente configurado durante la instalación de *Pharokka*. Este *script* invocaba al *anotar_bloque.sh* anterior, permitiendo así procesar los genomas en paralelo por bloques de 30, optimizando el uso de los recursos del sistema.




Figura 4. Diagrama de flujo del sistema de anotación de genomas mediante *Pharokka* en el clúster. Realización propia en *Lucid* (<https://lucid.app.com>).

Entre los ficheros de salida de *Pharokka* se encontraron:

- *pharokka_cds_final_merged_output.tsv*: tabla combinada con las asignaciones funcionales de las CDS basadas en las bases de datos PHROG, VFDB y CARD.

- *pharokka_length_gc_cds_density.tsv*: tabla resumen con información básica de cada contig como longitud, contenido GC y densidad de CDS.

3.2.3 Preprocesamiento y filtrado

Se elaboró y ejecutó un *script* de *Python* (Rossum & Drake, 2009) en su versión 3.9 en el entorno interactivo *Jupyter Notebook* (Kluyver et al., 2019). Este programa permitía guardar los bacteriófagos disponibles en el archivo VMR descargado, ya que filtraba aquellas filas cuya columna *Host source* contenía la palabra "bacteria", dejando de lado otros tipos de virus. Además, se aplicó un segundo filtrado para eliminar los bacteriófagos de la base de datos con genomas incompletos (*Genome coverage* = "Partial genome"). Los resultados se guardaron en un fichero llamado *fagos_filtrados.csv*.

Para conseguir los archivos FASTA de los genomas de los fagos presentes en *fagos_filtrados.csv* se desarrolló un segundo *script* de *Python*. Este programa permitió extraer los identificadores *Genbank* desde la columna *Virus GENBANK accession* del fichero *fagos_filtrados.csv* y, utilizando el módulo *Entrez* de la librería *Biopython*, realizar consultas a la página web del NCBI para descargar los ficheros de forma iterativa a través de su API leyendo cada fila del archivo CSV. El proceso incluía una pausa de 0.4 segundos entre cada descarga para evitar saturaciones y minimizar errores durante el proceso. Los resultados se almacenaron en una carpeta llamada *genomas_fagos*.

3.2.4. Generación y análisis del *dataset* final

Para la construcción del *dataset* final se integró la información funcional, taxonómica y genómica obtenida a partir de las bases de datos VMR y PHROG, así como los resultados de la anotación llevada a cabo con *Pharokka* (figura 5). Para ello, se creó y ejecutó un *script* de *Python* (versión 3.9) en el entorno interactivo *Jupyter Notebook* llamado *4_extraer_features_pharokka.ipynb*.

En primer lugar, se construyó una matriz binaria que reflejaba la presencia o ausencia de PHROG en los genomas anotados previamente. Los PHROG presentes o ausentes en cada uno se codificaron como variables binarias (1: presente y 0: ausente).

Después, se elaboró un archivo con la clasificación taxonómica oficial de cada genoma, extraída de la base de datos VMR del ICTV. Este archivo incluye los niveles taxonómicos más representativos (Reino, Filo, Clase, Familia, Género, y Especie) asociados a cada identificador genómico (*Virus GENBANK accession*).

Además, de los TSV obtenidos con *Pharokka* se extrajo información genómica como el tamaño del genoma, el porcentaje de contenido GC y el número de genes predichos por *Pharokka*.

Finalmente, los tres TSV conseguidos se fusionaron en una única matriz a través de los identificadores de los genomas. Con este paso se generó un archivo, que contiene, por cada genoma, las variables binarias de PHROG, su clasificación taxonómica y las variables genómicas.

En un paso final, se contrastaron las columnas PHROG presentes en la matriz del *dataset* con el listado completo de los PHROG presentes en la base de datos oficial (https://phrogs.lmge.uca.fr/virus_index.php). Los PHROG ausentes en la matriz fueron añadidos con valor 0 para todos los genomas, de forma que se asegure que en la matriz están representadas todas las variables PHROG posibles independientemente de si se encuentran o no entre los genomas disponibles. Con este proceso se generó la matriz final, que constituye el *dataset* principal de *PhageTax*.




Figura 5. Diagrama de flujo del proceso de construcción del *dataset* final utilizado en *PhageTax*. Realización propia en *Lucid* (<https://lucid.app.com>).

Una vez construida la matriz final de datos, se procedió analizando y caracterizando los datos almacenados en ella. Para ello, se creó y ejecutó un *script* de *Python* (versión 3.9) en el entorno interactivo *Jupyter Notebook* llamado *5_distribucion_features.ipynb*.

3.2.5. Análisis de frecuencia de PHROG por nivel taxonómico

Para determinar la distribución de los PHROG en los genomas de la matriz, esta se transformó a un formato largo mediante la función *melt* de *pandas*, separando las columnas de PHROG del resto de variables de la matriz. Después se calculó la frecuencia absoluta de cada PHROG dentro de cada nivel taxonómico, abarcando los seis niveles considerados (Especie, Género, Familia, Clase, Filo y Reino). Este análisis permitió detectar patrones de presencia comunes y evaluar el grado de conservación funcional de ciertos PHROG dentro de niveles taxonómicos, lo cual resulta clave para entender su valor discriminativo como predictores en el modelo

3.2.6. Identificación de PHROG característicos y específicos

Se identificaron los PHROG característicos, definidos como aquellos que están presentes en al menos un 80% de los genomas de un determinado nivel taxonómico, así como los PHROG específicos, entendidos como aquellos que sólo aparecen en un único nivel taxonómico. Este análisis se realizó de forma independiente para cada nivel taxonómico, generando tablas y gráficas de barras horizontales que recogen los PHROG característicos y específicos por cada nivel taxonómico, permitiendo estudiar posibles PHROG con poder de discriminación, lo que podía contribuir tanto a la interpretación biológica del modelo como a su capacidad predictiva.

3.2.7. Relación entre el número de PHROG y características genómicas

La relación del número de PHROG presentes en los genomas y su información genómica (tamaño del genoma, el contenido GC y el número de genes) fue analizada mediante matrices de correlación de *Pearson* (*.corr()* de *pandas*). Este análisis tuvo como objetivo evaluar si ciertas propiedades genómicas influyen en la riqueza funcional. Con ello, se buscó entender mejor los factores que pueden afectar a la representación funcional en los genomas y, por tanto, al rendimiento del modelo de clasificación.

3.3. Desarrollo del modelo multinivel taxonómico

Para la primera versión del modelo se aplicó un clasificador *Random Forest* (Breiman, 2001). encapsulado en un *MultiOutputClassifier* de *scikit-learn* (versión 1.5.2) en *Python* (versión 3.9) (<https://scikitlearn.org/stable/modules/generated/sklearn.multioutput.MultiOutputClassifier.html>), con el objetivo de predecir de forma simultánea los seis niveles taxonómicos elegidos: Reino, Filo, Clase, Familia, Género y Especie. Los clasificadores implementados en *scikit-learn*, como *Random Forest*, resultan especialmente útiles como componentes base en problemas multietiqueta, ya que permiten construir modelos más complejos, como los métodos basados en la partición del espacio de etiquetas (Szymanski & Kajdanowicz, 2017).

Se seleccionó *Random Forest* como modelo de clasificación por su robustez frente a datos de alta dimensionalidad, como los que presentaba la matriz binaria de PHROG. Este algoritmo permite manejar eficazmente variables irrelevantes, datos no lineales y desequilibrios entre clases. Además, su integración en *scikit-learn* facilita la optimización y validación del modelo. Otros enfoques como máquinas de vectores de soporte o SVM (Cortes & Vapnik, 1995) se descartaron por su menor interpretabilidad y peor escalabilidad en este tipo de datos.

3.3.1. Datos de entrada y procesamiento

Los datos utilizados para el entrenamiento del modelo fueron los extraídos de *matriz_phrogs_tax_gc_final.tsv*, generada previamente (apartado 3.2).

La división del dataset es crucial para la obtención de resultados. Para ello, se ha aplicado *train_test_split* de *scikit-learn* y estratificación sobre el nivel Clase. La orden “*train_test_split(X, y, test_size=0.2, stratify=y)*” divide las variables independientes X y la variable dependiente y en dos partes: entrenamiento y test en una proporción 80:20. Además, se aplicó el parámetro *stratify* para asegurar que las frecuencias relativas de las clases se preserven aproximadamente en cada subconjunto, es decir, en el conjunto de entrenamiento y en el de test (Ivanov et al., 2023). Para este modelo, la división de los datos se realizó en una proporción 80% para entrenamiento y 20% para test.

3.3.2. Entrenamiento del modelo

Para el entrenamiento del modelo se aplicó una estrategia de optimización de hiperparámetros mediante la función *GridSearchCV*. El optimizador *GridSearchCV* se emplea para identificar los valores óptimos de los hiperparámetros. Además, su capacidad de búsqueda exhaustiva lo convierte en una herramienta poderosa para el ajuste de hiperparámetros (Alemerien et al., 2024). Para este modelo se analizaron los siguientes parámetros del *Random Forest*:

- *n_estimators*: número de árboles en el bosque.
- *max_depth*: profundidad máxima de los árboles.
- *class_weight*: ajuste automático de los pesos de los niveles taxonómicos para compensar desbalances.

Cada combinación de parámetros fue evaluada mediante validación cruzada interna y se seleccionó aquella que produjo el mejor balance entre precisión y robustez del modelo. *GridSearchCV* calcula la puntuación de cada combinación de hiperparámetros y, finalmente, se elige la combinación de hiperparámetros con el mejor rendimiento para el modelo (Alemerien et al., 2024).

3.3.3. Evaluación y métricas obtenidas a partir del modelo

Para la evaluación del modelo entrenado se optó por emplear la función *Classification_report* de la librería *scikit-learn*. Esta herramienta proporciona de forma estructurada un resumen de las principales métricas de rendimiento del modelo, incluyendo *accuracy*, *recall* y F1-score (Kramer, 2016).

- *Accuracy*: mide la proporción de verdaderos positivos entre todos los positivos predichos.
- *Recall*: mide la capacidad del modelo para encontrar todos los positivos reales.
- F1-score: es la media armónica entre *accuracy* y *recall*, proporciona un balance entre ambas métricas.

Todas estas métricas se pueden generar a la vez con *metrics.Classification_report*. Esto permite estudiar de manera rápida y estandarizada el funcionamiento de los modelos de predicción. Además, también facilita la detección rápida de desequilibrios o limitaciones en el rendimiento de la predicción de cada nivel taxonómico, lo que es muy relevante en el análisis de clases desbalanceadas, ya que puede ser un caso habitual en la clasificación taxonómica de fagos.

3.4. Desarrollo de los modelos de ML para cada nivel taxonómico

Con el objetivo de optimizar el modelo inicial de clasificación se implementaron modelos finales aplicando nuevos enfoques orientados a su mejora.

Si bien el modelo inicial estaba basado en *MultiOutputClassifier*, donde cada nivel taxonómico se trató como una salida independiente, para este paso de optimización se siguió un enfoque diferente. La etapa de entrenamiento se realizó de forma independiente para cada nivel taxonómico, en lugar de un modelo conjunto, permitiendo optimizar hiperparámetros y preprocesamiento de forma específica. De esta forma se generó un modelo de predicción por cada nivel taxonómico a predecir.

Otra de las medidas de optimización fue la aplicación de un filtrado de genomas independiente por nivel taxonómico. De esta forma, se eliminaron aquellos grupos con menos de dos genomas de muestra, lo que fue un aspecto característico de niveles taxonómicos poco representados como Género y Especie. Además, para estos niveles también se calculó un *class_weight* específico y diferente al aplicado al modelo inicial. De esta manera, un grupo concreto que tuviese menos de dos genomas representantes era automáticamente descartado.

Por otra parte, se incorporó un refuerzo del peso de los PHROG específicos durante el proceso de generación de predictores. Para ello, se multiplicó el recuento de estos PHROG por un factor, con el fin de aumentar la relevancia de estos predictores altamente discriminativos.

A estos nuevos modelos también se les incluyó un paso adicional de validación cruzada de 5 particiones (*5-fold cross-validation*) sobre el conjunto de entrenamiento, permitiendo estimar de forma robusta el rendimiento del modelo antes de su evaluación final en *test*. La validación cruzada permitió obtener, para cada nivel taxonómico, la media y la desviación estándar de la exactitud obtenida en cada caso. Esto proporcionó datos menos dependientes de una única partición de los datos.

Por último, se generó una tabla complementaria que recogía información adicional para la interpretación biológica y la detección de predicciones dudosas. Por cada genoma se representaba:

- El número de PHROG específicos presentes correspondientes al género y especie predichos, calculado a partir de una lista de PHROG específicos por grupo generada previamente.
- Avisos automáticos generados para informar de si la confianza de la predicción (probabilidad asignada por el clasificador) es inferior al umbral de confianza de 0.7,

considerado indicativo de baja fiabilidad, y si no se detecta la presencia de ningún PHROG específicos para esos grupos taxonómicos predichos.

Estos avisos podrían ser útiles como apoyo a una posterior validación manual de los resultados, además de para poder hacer foco en los PHROG más informativos del genoma de interés.

3.5 Diferencias entre los modelos de ML implementados

Como muestra la tabla 1, el modelo multinivel inicial sirvió como punto de partida, revelando limitaciones asociadas al desequilibrio de clases y la falta de predictores específicos. Los modelos específicos finales incorporaron información biológica adicional (como los PHROG específicos), ajustes amoldados a grupo taxonómico y un sistema de avisos.

ENFOQUE	MODELO MULTINIVEL	MODELOS ESPECÍFICOS
Variables predictoras utilizadas	Sólo matriz binaria de PHROG	Matriz binaria de PHROG + PHROG característicos y específicos por grupo en cada nivel taxonómico
Optimización de hiperparámetros	<i>GridSearchCV</i> aplicado de forma estándar	Optimización específica por nivel taxonómico, incluyendo ajustes de pesos y selección de predictores
Predicción multietiqueta	Sí, <i>MultiOutputClassifier</i> aplicado sobre todos los niveles a la vez	No, entrenamiento y optimización independiente por nivel
Análisis previo limitaciones	No, el modelo se entrena directamente	Sí, se identifican géneros poco representados y se adapta el entrenamiento
Sistema de avisos de confianza	No implementado	Sí, basado en probabilidad de predicción, PHROG específicos presentes...
Estrategia en los niveles Género y Especie	Pesos iguales que el resto de los niveles	Filtrado de géneros poco representados (mínimo 2 genomas) antes de entrenar

Tabla 1. Comparación de los enfoques aplicados en el modelo inicial frente a los modelos desarrollados para el prototipo final de la herramienta *PhageTax*.

4. Resultados y discusión

4.1. *PhageTax*

Las etapas de análisis funcional (E), entrenamiento del modelo (F) y predicción (G) mostradas en la Figura 3 han sido automatizadas en la herramienta *PhageTax*.

PhageTax es una herramienta bioinformática de código abierto desarrollada en Python y diseñada para realizar la clasificación taxonómica automática de bacteriófagos a partir de sus secuencias genómicas. La herramienta integra los scripts descritos en la sección 3 y los modelos de aprendizaje automático previamente entrenados (*Random Forest*), permitiendo predecir la pertenencia taxonómica de un genoma viral en seis niveles jerárquicos: Reino, Filo, Clase, Familia, Género y Especie.

PhageTax está disponible públicamente en Github (<https://github.com/marinartmonkey/phagetax>) junto con documentación detallada, guía de uso, ejemplos de uso, los modelos generados y los resultados obtenidos en este trabajo.

Para la validación del método de clasificación taxonómica propuesto en este trabajo, se han generado con *PhageTax* los dos modelos de ML descritos en la sección 3. La etapa de generación del *dataset* es común a ambos. En las siguientes secciones se describen los resultados obtenidos en la validación.

4.2. Construcción y análisis del dataset.

La metodología de construcción del *dataset* está detallada en la sección 3.2. Brevemente, la primera etapa en el flujo de trabajo de este trabajo es la selección, en formato FASTA, de genomas de bacteriófagos que correspondan a los diferentes niveles taxonómicos recogidos en el VMR. Siguiendo el protocolo descrito en el subapartado 3.2.2 se almacenaron un total de 6.730 genomas. Este tamaño muestral fue adecuado para los análisis posteriores, ya que permitió entrenar modelos de ML pudiendo dividir los datos en entrenamiento y *test* adecuadamente evitando *overfitting*.

La anotación de los genomas fue realizada utilizando el programa *Pharokka* (Bouras et al., 2022). Para ilustrar el proceso de anotación, se ha seleccionado al genoma AB002632 perteneciente al fago fs2 de *Vibrio* (<https://www.ncbi.nlm.nih.gov/nuccore/AB002632.1/>). La tabla 2 muestra la información genómica obtenida en este caso.

INFORMACIÓN OBTENIDA	VALORES
Longitud del genoma	8.651 nucleótidos
Porcentaje de contenido GC	45%
Número total de CDS anotadas	14
Proteínas identificadas	Cápside, cabeza, proteínas de morfogénesis, proteínas de ensamblaje, proteínas implicadas en la replicación, una <i>hypothetical protein</i>
PHROG identificados en 13 CDS	929, 91, 5738, 7781, 31084, 1646, 1698, 1944, 1675, 1012, 1668, 6488
CDS sin correspondencia con PHROG	1 (etiquetado como <i>No_PHROG</i>)

Tabla 2. Resumen de la información obtenida tras el proceso de anotación con *Pharokka* para el fago fs2 de *Vibrio*.

El *dataset* final generado para la herramienta bioinformática *PhageTax* (*matriz_phrogs_tax_gc_final.tsv*, ver subapartado 3.1.4 y figura 5) contó con 38.890 columnas (Reino, Filo, Clase, Familia, Género, Especie, *genome_length*, *gc_percent*, *num_genes* y *PHROG_1 ... PHROG_38880*) y una fila por cada genoma. Este conjunto de datos representó una base de datos robusta y eficiente para análisis posteriores y el desarrollo de un modelo de ML que se pueda aplicar para la clasificación taxonómica de bacteriófagos.

El estudio de la distribución de genomas en los géneros del *dataset* relevó un notable desbalance. La mayoría de los géneros analizados (1.219) estaban representados únicamente por un único genoma, mientras que 337 géneros contaron con dos genomas, 216 géneros disponían de entre 3 y 4 genomas, y únicamente 262 géneros presentaron una representación de cinco o más genomas (figura 6).




Figura 6. Distribución de géneros según el número de genomas disponibles en el *dataset*.

Además, la distribución de géneros poco representados no fue homogénea entre las familias del *dataset*. Los géneros con 1 o 2 genomas se concentran principalmente en determinadas familias, entre ellas *Atkinsviridae* con 631 géneros poco representados, seguida de *Fiersviridae* (115), *Steitzviridae* (59), *Kyanoviridae* (58) y *Schitoviridae* (51). Esta tendencia sugirió que podían existir factores externos que afectaban a la baja representación de los genomas en grupos taxonómicos concretos, como puede ser el bajo número de fagos detectados, bien sea por aislamiento o por análisis metagenómicos, que sean pertenecientes a dichos grupos. Esto supuso una limitación en el rendimiento del modelo multinivel de clasificación, ya que los géneros que englobaban pocos genomas no podían ser incluidos correctamente en los conjuntos de validación.

4.3. Análisis del modelo predictivo multinivel para clasificación taxonómica

4.3.1. Evaluación del modelo multinivel

El modelo multinivel inicial consistía en un único clasificador *Random Forest* entrenado para predecir simultáneamente los seis niveles taxonómicos (Reino, Filo, Clase, Familia, Género y Especie) en una única etapa. Si bien este enfoque permite una clasificación de forma directa, presentaba limitaciones en los niveles más bajos, especialmente cuando las clases estaban desbalanceadas o pobremente representadas. Posteriormente, se desarrollaron modelos independientes por nivel taxonómico, cada uno entrenado y ajustado por separado, lo que permitió optimizar el rendimiento y la precisión en cada uno de los niveles, particularmente en Género y Especie.

A continuación, se describen los resultados obtenidos con el modelo multinivel, así como su rendimiento en los distintos niveles taxonómicos.

Las combinaciones de hiperparámetros elegidas fueron:

- *n_estimators*: 100 árboles.
- *max_depth*: sin límite de profundidad (*None*) o limitado a 10 niveles.
- *class_weight*: ajuste automático de pesos de las clases (*balanced*).

Con esto, el entrenamiento se completó de manera exitosa y se obtuvieron las métricas de rendimiento mostradas en la tabla 3.

NIVEL TAXONÓMICO	ACCURACY	RECALL	F1-SCORE
Reino	1.00	1.00	1.00
Filo	1.00	1.00	1.00
Clase	1.00	1.00	1.00
Familia	0.88	0.93	0.92
Género	0.67	0.43	0.41
Especie	0.02	0.01	0.01

Tabla 3. Métricas de rendimiento del modelo multinivel de clasificación taxonómica por nivel jerárquico. Se muestran los valores de *Accuracy*, *Recall* y F1-Score para cada nivel taxonómico.

La predicción para los niveles Reino, Filo y Clase alcanzó valores de *accuracy* de 1.00, lo que indica que el modelo es capaz de clasificar los genomas en los niveles más generales de forma eficiente. En el nivel Familia, el valor del parámetro *accuracy* desciende al 0.88. En este caso los valores de recall y F1-score son superiores 0.93 y 0.92, respectivamente.

El rendimiento de la predicción taxonómica de los niveles Género y Especie puede definirse como un factor limitante del rendimiento global del modelo, ya que en ambos casos el valor de *accuracy* es inferior a 0.70.

4.3.2. Relación entre el número de genomas en un género y el rendimiento del modelo

Dado que la clasificación taxonómica basada en ML requiere una representación suficiente de cada grupo para que el modelo pueda aprender patrones discriminativos, es esperable que los géneros poco representados presenten un peor rendimiento. Identificar y cuantificar esta relación permite no sólo interpretar correctamente los resultados del modelo, sino también establecer recomendaciones sobre el tamaño mínimo de muestra necesario para obtener predicciones fiables en futuros análisis. El análisis de la relación entre el número de genomas presentes por género y el rendimiento predictivo obtenido, medido a través del F1-score, puso de manifiesto una clara influencia de la baja representación genómica en la capacidad de predicción del modelo.

En la figura 7 se muestran dos visualizaciones complementarias que exploran esta relación. El gráfico de dispersión representa el F1-score obtenido por género en función del número de genomas disponibles. Se observa que, aunque algunos géneros con muy pocos genomas (incluso uno solo) pueden alcanzar un F1-score alto, generalmente presentan valores cercanos a cero, evidenciando una elevada variabilidad en estos rangos. A medida que aumenta el número de genomas, el rendimiento mejora progresivamente y los valores de F1-score se estabilizan.

Esta tendencia se refuerza en el gráfico de cajas, que agrupa los géneros según rangos de número de genomas. En él se observa que los grupos con mayor representación genómica presentan distribuciones de F1-score más elevadas y menos dispersas. Estos resultados evidencian la influencia directa del tamaño de muestra sobre el rendimiento del modelo y destacan la necesidad de contar con una representación mínima por género para obtener resultados fiables.




Figura 7. Relación entre el número de genomas por género y el rendimiento predictivo del modelo. A la izquierda, gráfico de dispersión que muestra el F1-score en función del número de genomas disponibles por género. A la derecha, gráfico de cajas que representa la distribución del F1-score agrupando los géneros por rangos de tamaño.

Estos resultados ponen de manifiesto la influencia del número de genomas en los géneros analizados en el rendimiento del modelo y evidencian la necesidad de contar con un tamaño de muestra mínimo por género para que el modelo pueda generalizar correctamente.

Con el objetivo de profundizar en los factores que podrían estar condicionando el rendimiento del modelo inicial, se realizó una comparación cuantitativa entre los géneros que obtuvieron buenos resultados de clasificación ($F1 > 0,7$) y aquellos en los que el modelo mostró dificultades ($F1 \leq$

0,7). Al comparar la mediana y el p-valor (prueba de Mann-Whitney) de cada variable entre los géneros bien y mal clasificados los resultados fueron los siguientes:

Se observó que los géneros que se clasificaron correctamente tendieron a presentar un mayor número de genomas en el conjunto de datos, ya que la mediana de genomas en el grupo bien clasificado fue de 5, frente a sólo 1 en los géneros mal clasificados (figura 8). Esta diferencia fue estadísticamente significativa ($p < 0.0001$), lo que indicó que el tamaño de muestra disponible por género influía significativamente en el rendimiento del modelo.




Figura 8. Distribución del número de genomas por género según el rendimiento del modelo.

4.3.3. Relación entre el número de PHROG en un género y el rendimiento del modelo

Al analizar el número de PHROG característicos (>80%), en los géneros analizados se observó un mayor número de PHROG característicos en los géneros correctamente clasificados (mediana de 45) en comparación con los mal clasificados (mediana de 34) (Figura 9). Esta diferencia fue significativa ($p < 0.0001$), lo que sugirió que la conservación de PHROG característicos dentro de un género facilitó su detección por el modelo.




Figura 9. Comparativa del número de PHROG característicos (>80%) por género en función del rendimiento del modelo.

En cuanto al número de PHROG específicos, los géneros con un mayor número de PHROG específicos tendieron a clasificarse de forma más precisa (Figura 10). Los géneros bien clasificados presentaron una mediana de 4 PHROG específicos, mientras que los mal clasificados no presentaron ninguno en la mayoría de los casos (mediana = 0). Esta variable también mostró asociación con el rendimiento del modelo ($p < 0.0001$).




Figura 10. Relación entre el número de PHROG específicos y el rendimiento de la clasificación por género.

Estos resultados indicaron que tanto el tamaño de genomas disponibles en el género, así como la presencia de PHROG característicos y específicos son factores clave que explicaban las diferencias en el rendimiento del modelo de clasificación taxonómica a este nivel taxonómico.

4.4. Evaluación de los modelos específicos para los niveles taxonómicos

Los resultados obtenidos con el modelo predictivo multinivel indicaron que la precisión de la clasificación a nivel de género estaba fuertemente influenciada por el número de genomas disponibles en cada grupo. En consecuencia, en los modelos finales se aplicó un filtro taxonómico que excluyó los niveles de Género y Especie con menos de dos genomas, lo que permitió reducir el impacto del desbalance en las clases minoritarias.

Por otro lado, también se observó que los PHROG característicos y específicos estaban estrechamente asociados al rendimiento del modelo: los géneros con mayor número de estos PHROG tendieron a clasificarse mejor. A partir de esta observación, se incorporó un refuerzo del peso de los PHROG específicos durante la generación de predictores, multiplicando su recuento por un factor de 3. Este valor fue seleccionado tras probar distintos factores de ponderación (1, 3, 10, 50 y 100), observando que el rendimiento no mejoraba significativamente con valores mayores.

Estas modificaciones contribuyeron a mejorar la capacidad del modelo para clasificar grupos taxonómicos complejos y poco representados, sin introducir sobreajustes.

En la figura 11 se presentan los resultados de rendimiento obtenidos para los modelos finales y cada nivel taxonómico. Se muestran los valores de *accuracy* y F1-score calculados en el conjunto de *test*, así como la media y desviación estándar de la validación cruzada realizada durante el entrenamiento.




Figura 11. Comparativa de métricas de rendimiento por nivel taxonómico. Se muestran los valores de acierto (barras azules) y F1-score (línea verde) en el conjunto de *test*, junto con la media y desviación estándar del acierto obtenidas mediante validación cruzada (puntos rojos con barras de error).

En líneas generales, la comparación de las métricas de clasificación obtenidas con el prototipo inicial y final para cada nivel taxonómico revela una mejora sustancial del rendimiento en los niveles más específicos (tabla 4).

NIVEL TAXONÓMICO	ACCURACY (INICIAL)	F1-SCORE (INICIAL)	ACCURACY (FINAL)	F1-SCORE (FINAL)	CV MEDIA ± STD (FINAL)
Reino	1.00	1.00	1.00	1.00	0.999 ± 0.001
Filo	1.00	1.00	1.00	1.00	0.999 ± 0.001
Clase	1.00	1.00	1.00	1.00	0.999 ± 0.001
Familia	0.88	0.92	0.86	0.87	0.853 ± 0.013
Género	0.67	0.41	0.83	0.82	0.809 ± 0.008
Especie	0.02	0.01	0.96	0.95	0.675 ± 0.203

Tabla 4. Métricas de rendimiento del prototipo inicial y final de la herramienta para cada taxonómico. Se muestran los valores de *accuracy* y F1-score obtenidos en el conjunto de *test*, así como la media y desviación estándar calculadas mediante validación cruzada (CV Media ± Std) para cada nivel taxonómico.

Las métricas indicaron que los modelos alcanzaron un rendimiento prácticamente perfecto en los niveles más generales (Reino, Filo y Clase), con valores de *accuracy* y F1-score próximos a 1.00, reflejando una alta capacidad del modelo para distinguir entre los grupos taxonómicos en estos niveles.

El nivel Familia presentó un leve descenso del rendimiento con respecto a los niveles superiores, donde *accuracy* y F1-score se situaron en torno a 0.85.

La mayor diferencia entre el modelo multinivel y los modelos específicos se alcanza con los niveles Género y Especie, definidos anteriormente como los niveles limitantes del rendimiento de la herramienta. A nivel de género, tanto *accuracy* como el F1-score se sitúan alrededor de 0.85, lo que supone un incremento de la precisión de su modelo predictivo (en el modelo del prototipo inicial *accuracy* fue 0.67 y F1-score 0.41). Esto demostró que este modelo es capaz de distinguir los géneros de forma mucho más fiable.

A nivel de especie, el F1-score alcanza valores cercanos a 0.95 (en el modelo inicial el valor era de 0.02). A pesar de ello, la alta variabilidad observada en la validación cruzada (0.675 ± 0.203) sugiere que aún hay limitaciones que persisten en la estabilidad del modelo. Esto se confirma al

observar que sólo se han analizado 28 especies en el conjunto de *test* debido al filtro aplicado para no tener en cuenta especies con menos de 2 genomas de muestra.

Esta mejora general en el rendimiento de los modelos pone de manifiesto la eficacia de adaptar el entrenamiento a las particularidades de cada nivel taxonómico, así como la importancia de incorporar información biológica relevante, como los PHROG específicos, en el proceso de clasificación. No obstante, los resultados también evidencian que, incluso con un modelo optimizado, la complejidad biológica y las limitaciones inherentes a los datos, como el bajo número de genomas en ciertos grupos o la alta variabilidad genómica, siguen condicionando la capacidad del modelo para una precisa clasificación taxonómica, especialmente en los niveles de género y especie.

Por otra parte, el análisis de las predicciones de los modelos generados por *PhageTax* revela una proporción considerable de casos con baja confianza, especialmente en los niveles taxonómicos inferiores (tabla 5). En concreto, un 30,5 % de las predicciones a nivel de género presentaron una probabilidad inferior al umbral de 0.7, mientras que en el caso del nivel especie, este porcentaje se elevó hasta el 98,0 %.

En paralelo, el análisis del número de PHROG específicos presentes en los genomas mostró diferencias notables entre los niveles de género y especie (tabla 5). A nivel de género, los genomas presentaron una media de 5,03 PHROG específicos, con una mediana de 1, mientras que el 47,6 % de los genomas no contenía ningún PHROG específico asociado al género predicho. En cambio, a nivel de especie, la presencia de PHROG específicos fue prácticamente residual: la media fue de 0,02, la mediana de 0, y el 98,9 % de los genomas carecía de cualquier PHROG asociado a la especie predicha.

NIVEL TAXONÓMICO	PREDICCIONES CON CONFIANZA < 0.7 (%)	MEDIA PHROG ESPECÍFICOS	MEDIANA PHROG ESPECÍFICOS	GENOMAS SIN PHROG ESPECÍFICOS (%)
Género	30,5 %	5,03	1	47,6 %
Especie	98,0 %	0,02	0	98,9 %

Tabla 5. Resumen de las predicciones con baja confianza y la presencia de PHROG específicos en los genomas clasificados por *PhageTax*.

Estos resultados ponen de manifiesto que cuando *PhageTax* emite una predicción con baja confianza a nivel de género o especie, y además no se detectan PHROG específicos correspondientes al grupo predicho, el investigador debe interpretar el resultado con especial precaución. Esta combinación puede ser indicativa de que el genoma pertenece a un grupo pobremente representado en el conjunto de entrenamiento, lo que limita la capacidad del modelo para clasificarlo de forma fiable. Desde un punto de vista biológico, también podría sugerir que se trata de un grupo nuevo o poco caracterizado. Por este motivo, la herramienta genera avisos automáticos que permiten al usuario identificar este tipo de casos y considerar la realización de análisis complementarios que confirmen o descarten la posible novedad taxonómica del genoma analizado.

4.5. Resultados para una selección de genomas virales de clasificación conocida

Para la aplicación de *PhageTax* se han seleccionado genomas virales no disponibles en el *dataset* y cuyas clasificaciones taxonómicas son conocidas a diferentes niveles. Se han elegido estos ejemplos por corresponder a fagos para los que existen diferentes cantidades de representantes a los distintos niveles taxonómicos y, por tanto, pueden ayudar a la complejidad inherente a la clasificación taxonómica de fagos y los límites actuales de los modelos predictivos.

En primer lugar, se seleccionó al fago CPG1g de *Marinomonas* (disponible en <https://www.ncbi.nlm.nih.gov/nuccore/KY626177.1>), que infecta a una bacteria aislada del agua de mar de la costa del Mar Mediterráneo. Su taxonomía según VMR es *Viruses* (Acelular); *Duplodnaviria* (Dominio); *Heunggongvirae* (Reino); *Uroviricota* (Filo); *Caudoviricetes* (Clase);

Autographivirales (Orden); *Autosignataviridae* (Familia) *Colwellvirinae* (Subfamilia); *Murciavirus* (Género). En el *dataset* de *PhageTax* sólo se recoge una única entrada en el género *Murciavirus*.

También se incluyó el fago SIO-2 de *Vibrio* (disponible en (https://www.ncbi.nlm.nih.gov/nuccore/NC_016567.1), cuya taxonomía sólo es conocida a nivel de clase (*Viruses*; *Duplodnaviria*; *Heunggongvirae*; *Uroviricota*; *Caudoviricetes*). Esta clase está presente en el *dataset* y usar la herramienta podría servir para conocer la taxonomía de este fago a niveles más bajos.


Por último, el fago T4 de *Escherichia* (<https://www.ncbi.nlm.nih.gov/nuccore/OZ209057.1>). Su taxonomía es *Viruses*; *Duplodnaviria*; *Heunggongvirae*; *Uroviricota*; *Caudoviricetes*; *Straboviridae*; *Tevenvirinae*; *Tequatrovirus*; *Tequatrovirus T4* y, por tanto, es conocida a nivel de especie. El género *Tequatrovirus* estaba presente en el *dataset* en más de 80 genomas, pero la especie no estaba recogida.

Para llevar a cabo este proceso se preparan los genomas a analizar y se anotan automáticamente con *Pharokka* a partir de las secuencias FASTA de estos, descargadas del NCBI. Con las anotaciones se generaron las matrices de presencia/ausencia de PHROG y una matriz final que integra taxonomía, PHROG y características genómicas. Esta matriz se adapta al formato requerido por los modelos previamente entrenados y se aplica la predicción taxonómica para cada nivel (Reino, Filo, Clase, Familia, Género, Especie), obteniendo la clasificación, los PHROG específicos y característicos y el nivel de confianza por genoma.

Los resultados obtenidos con *PhageTax* para la predicción taxonómica de fagos externos al *dataset* de entrenamiento, como los fagos CPG1g, SIO-2 y T4 (figura 12B), son consistentes con lo esperado para los modelos finales de la herramienta y están disponibles en <https://github.com/marinartmonkey/phagetax/blob/main/tests/predicciones.tsv>.

En el caso del fago CPG1g, su género (*Murciavirus*) se encontraba infrarrepresentado en el *dataset* de entrenamiento, con únicamente un genoma disponible. Como consecuencia, *PhageTax* no incluye este género en el proceso de entrenamiento y, por tanto, no puede predecirlo correctamente. Esto se refleja en la predicción errónea obtenida y en el bajo nivel de confianza asociado al nivel de género (figura 12A). Sin embargo, la familia si es predicha correctamente en correspondencia con el alto nivel de confianza. Una situación similar se observa para el fago SIO-2, cuya clasificación taxonómica únicamente se conoce hasta nivel de clase. En este caso, *PhageTax* devuelve niveles de confianza muy bajos en los niveles taxonómicos inferiores (Familia: 0.11, Género: 0.05, Especie: 0.20, figura 12A), lo que indica la ausencia de información suficiente en el modelo para realizar una predicción fiable. Para este tipo de casos, en los que se analizan fagos que pertenecen a grupos taxonómicos poco explorados o aún no descritos, se recomienda complementar la predicción con el estudio de los PHROG característicos y específicos para cada uno de los grupos taxonómicos presentes en el genoma, información que *PhageTax* proporciona de manera automática. Asimismo, se aconseja consultar manualmente las bases de datos oficiales de los PHROG (<https://phrogs.lmge.uca.fr/>) para profundizar en la interpretación funcional y taxonómica de estos genomas.

Un caso distinto es el del fago T4, que ejemplifica cómo *PhageTax* es capaz de realizar una predicción precisa cuando el grupo taxonómico al que pertenece (el género *Tequatrovirus*, en este caso) se encuentra más representado en el *dataset* de entrenamiento. Esto queda reflejado tanto en la clasificación final como en los elevados niveles de confianza obtenidos hasta el nivel de género (figura 12A), lo que demuestra que la herramienta puede predecir de forma eficiente cuando dispone de información suficiente durante el entrenamiento.



GENOMA	REINO	FILO	CLASE	FAMILIA	GÉNERO	ESPECIE
CPG1g	Heunggongvirae	Uroviricota	Caudoviricetes	Autosignataviridae	Nerthusvirus	Tertilicivirus Pf3
T4	Heunggongvirae	Uroviricota	Caudoviricetes	Straboviridae	Tequatrovirus	Inovirus M13
SIO-2	Heunggongvirae	Uroviricota	Caudoviricetes	Peduviridae	Namikivirus	Inovirus M13

Figura 12. Resultados de la predicción taxonómica con *PhageTax* para los genomas de prueba. (A) Arriba se muestran las correspondientes puntuaciones de confianza y, abajo, los grupos asignados a cada nivel taxonómico, destacando en amarillo los correctos. (B).

4.6. Aplicabilidad y perspectivas futuras

PhageTax nace de la necesidad de facilitar y acelerar la clasificación taxonómica de nuevos fagos, una tarea que tradicionalmente requiere análisis filogenéticos complejos y búsquedas manuales en bases de datos. En este contexto, los resultados obtenidos con *PhageTax* son relevantes: una precisión del 0.83 a nivel de género, por ejemplo, implica que en más de 8 de cada 10 casos el modelo es capaz de asignar correctamente la clasificación sin necesidad de intervención adicional. Este rendimiento puede traducirse en un ahorro considerable de tiempo para el investigador, al permitir una primera asignación automática que posteriormente puede ser validada o refinada.

Además, la disponibilidad de modelos independientes por nivel taxonómico ofrece flexibilidad a la hora de adaptarla a distintos escenarios dependiendo de la intención del usuario que los aplique.

Aunque en esta primera versión no se ha llevado a cabo una comparación directa con otras herramientas existentes, como *VIBRANT*, *ViralClassifier* o *TaxmyPHAGE*, esta sería una nueva línea de trabajo a abordar en futuras versiones. Evaluar el rendimiento de *PhageTax* frente a otras herramientas puede permitir contextualizar mejor sus puntos fuertes y limitaciones, así como identificar oportunidades de mejora o integración con otros enfoques complementarios.

5. Conclusiones

Como resultado de este trabajo se desarrolló *PhageTax*, una herramienta bioinformática diseñada para la predicción automática de la clasificación taxonómica de bacteriófagos a partir de la información extraída de sus genomas y la base de datos VMR del ICTV, disponible en <https://github.com/marinartmonkey/phagetax>.

PhageTax combina la anotación funcional mediante *Pharokka*, el análisis de presencia/ausencia de PHROG, la integración de predictores adicionales (como los PHROG específicos) y un sistema de avisos basado en la confianza de las predicciones. La herramienta ha sido validada en un conjunto de datos de referencia y aplicada posteriormente a nuevos genomas de fagos, demostrando su aplicabilidad y robustez en escenarios reales.

PhageTax representa un avance respecto a las estrategias clásicas de clasificación taxonómica de fagos, ya que:

- Permite integrar información funcional directamente derivada de los PHROG, en lugar de basarse exclusivamente en alineamientos de secuencias o comparaciones filogenéticas.
- Incorpora un sistema de predicción probabilístico basado en modelos de *Random Forest* entrenados específicamente para la clasificación taxonómica de fagos.
- El uso combinado de predictores específicos y estrategias de entrenamiento adaptadas a cada grupo taxonómico mejoran significativamente la precisión de la clasificación, especialmente en los niveles taxonómicos más específicos, tradicionalmente difíciles de abordar.
- *PhageTax* ofrece avisos que permiten al usuario interpretar la fiabilidad de las predicciones obtenidas.

6. Relación del trabajo con los Objetivos de Desarrollo Sostenible

Este trabajo se alinea directamente con el Objetivo de Desarrollo Sostenible (ODS) número 3: "Salud y bienestar", así como con el ODS 9: "Industria, innovación e infraestructura".

La herramienta *PhageTax* contribuye al ODS 3 al facilitar la identificación y clasificación de bacteriófagos, virus con un enorme potencial en el desarrollo de terapias alternativas frente a infecciones bacterianas, especialmente aquellas causadas por cepas multirresistentes a los antibióticos. Esta problemática representa una de las mayores amenazas sanitarias a nivel global, como reconoce la OMS, y el avance en la taxonomía y caracterización de fagos es un paso esencial para el desarrollo de terapias efectivas basadas en ellos.

Asimismo, *PhageTax* se encuadra en el ODS 9, ya que representa un ejemplo de innovación tecnológica aplicada al ámbito de la biotecnología y la bioinformática, promoviendo el desarrollo de software de código abierto, que impulsa el progreso científico y la investigación colaborativa a nivel internacional.

7. Bibliografía

Toda la bibliografía utilizada a lo largo de este trabajo ha sido citada siguiendo el formato y las normas del estilo APA (*American Psychological Association*).

- Ackermann, H., & Eisenstark, A. (1974). The Present State of Phage Taxonomy. *Intervirology*, 3(4), 201-219. <https://doi.org/10.1159/000149758>
- Albin, D., Ramsahoye, M., Kochavi, E., & Alistar, M. (2024). PhageScanner: a reconfigurable machine learning framework for bacteriophage genomic and metagenomic feature annotation. *Frontiers In Microbiology*, 15. <https://doi.org/10.3389/fmicb.2024.1446097>
- Alcock, B. P., Huynh, W., Chalil, R., Smith, K. W., Raphenya, A. R., Wlodarski, M. A., Edalatmand, A., Petkau, A., Syed, S. A., Tsang, K. K., Baker, S. J. C., Dave, M., McCarthy, M. C., Mukiri, K. M., Nasir, J. A., Golbon, B., Imtiaz, H., Jiang, X., Kaur, K., . . . McArthur, A. G. (2022). CARD 2023: expanded curation, support for machine learning, and resistome prediction at the Comprehensive Antibiotic Resistance Database. *Nucleic Acids Research*, 51(D1), D690-D699. <https://doi.org/10.1093/nar/gkac920>
- Alemerien, K., Alsayregh, S., Altarawneh, E. (2024). Diagnosing Cardiovascular Diseases using Optimized Machine Learning Algorithms with GridSearchCV. *Journal Of Applied Data Sciences*, 5(4), 1539-1552. <https://doi.org/10.47738/jads.v5i4.280>
- Appelt, S., Fancello, L., Bailly, M. L., Raoult, D., Drancourt, M., & Desnues, C. (2014). Viruses in a 14th-Century Coprolite. *Applied And Environmental Microbiology*, 80(9), 2648-2655. <https://doi.org/10.1128/aem.03242-13>
- Benson, D. A., Cavanaugh, M., Clark, K., Karsch-Mizrachi, I., Lipman, D. J., Ostell, J., & Sayers, E. W. (2012). GenBank. *Nucleic Acids Research*, 41(D1), D36-D42. <https://doi.org/10.1093/nar/gks1195>
- Bland, C., Ramsey, T. L., Sabree, F., Lowe, M., Brown, K., Kyripides, N. C., & Hugenholtz, P. (2007). CRISPR Recognition Tool (CRT): a tool for automatic detection of clustered regularly interspaced palindromic repeats. *BMC Bioinformatics*, 8(1). <https://doi.org/10.1186/1471-2105-8-209>

- Bouras, G., Nepal, R., Houtak, G., Psaltis, A. J., Wormald, P., & Vreugde, S. (2022b). Pharokka: a fast scalable bacteriophage annotation tool. *Bioinformatics*, 39(1). <https://doi.org/10.1093/bioinformatics/btac776>
- Bradley, D. E. (1967). Ultrastructure of bacteriophage and bacteriocins. *Bacteriological Reviews*, 31(4), 230-314. <https://doi.org/10.1128/br.31.4.230-314.1967>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Caetano-Anollés, G., Claverie, J., & Nasir, A. (2023b). A critical analysis of the current state of virus taxonomy. *Frontiers In Microbiology*, 14. <https://doi.org/10.3389/fmicb.2023.1240993>
- Chan, P. P., & Lowe, T. M. (2019). tRNAscan-SE: Searching for tRNA Genes in Genomic Sequences. *Methods In Molecular Biology*, 1-14. https://doi.org/10.1007/978-1-4939-9173-0_1
- Chen, L., Yang, J., Yu, J., Yao, Z., Sun, L., Shen, Y., & Jin, Q. (2005). VFDB: a reference database for bacterial virulence factors. *Nucleic acids research*, 33(Database issue), D325–D328. <https://doi.org/10.1093/nar/gki008>
- Chibani, C. M., Farr, A., Klama, S., Dietrich, S., & Liesegang, H. (2019). Claseifying the unClaseified: A phage Claseification method. *Viruses*, 11(2), 195. <https://doi.org/10.3390/v11020195>
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- Eddy, S. R. (1998). Profile hidden Markov models. *Bioinformatics*, 14(9), 755-763. <https://doi.org/10.1093/bioinformatics/14.9.755>
- Hyatt, D., Chen, G., LoCascio, P. F., Land, M. L., Larimer, F. W., & Hauser, L. J. (2010). Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC Bioinformatics*, 11(1). <https://doi.org/10.1186/1471-2105-11-119>
- Ivanov, I., Toleva, B., & Hooper, V. J. (2023). A fast and effective approach for Claseification medical data sets. *Int. J. Innov. Res. Sci. Stud*, 6, 545-552.
- Kieft, K., Zhou, Z., & Anantharaman, K. (2020). VIBRANT: automated recovery, annotation and curation of microbial viruses, and evaluation of viral community function from genomic sequences. *Microbiome*, 8(1). <https://doi.org/10.1186/s40168-020-00867-0>
- Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B., Bussonnier, M., Frederic, J., ... Willing, C. (2016). Jupyter Notebooks – a publishing format for reproducible computational workflows. In F. Loizides & B. Schmidt (Eds.), *Positioning and Power in Academic Publishing: Players, Agents and Agendas* (pp. 87–90).
- Kramer, O. (2016). Scikit-Learn. En *Studies in big data* (pp. 45-53). https://doi.org/10.1007/978-3-319-33383-0_5
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50–60. <https://doi.org/10.1214/aoms/1177730491>
- McNair, K., Zhou, C., Dinsdale, E. A., Souza, B., & Edwards, R. A. (2019). PHANOTATE: a novel approach to gene identification in phage genomes. *Bioinformatics*, 35(22), 4537-4542. <https://doi.org/10.1093/bioinformatics/btz265>
- Meier-Kolthoff, J. P., & Göker, M. (2017). VICTOR: genome-based phylogeny and Claseification of prokaryotic viruses. *Bioinformatics*, 33(21), 3396-3404. <https://doi.org/10.1093/bioinformatics/btx440>
- Millard, A., Denise, R., Lestido, M., Thomas, M., Turner, D., Turner, D., & Sicheritz-Pontén, T. (2024). taxmyPHAGE: Automated taxonomy of dsDNA phage genomes at the Género and Especie level. *bioRxiv (Cold Spring Harbor Laboratory)*. <https://doi.org/10.1101/2024.08.09.606593>
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- Nigro, O. D., Jungbluth, S. P., Lin, H., Hsieh, C., Miranda, J. A., Schvarcz, C. R., Rappé, M. S., & Steward, G. F. (2017). Viruses in the Oceanic Basement. *mBio*, 8(2). <https://doi.org/10.1128/mbio.02129-16>
- Nishimura, Y., Yoshida, T., Kuronishi, M., Uehara, H., Ogata, H., & Goto, S. (2017b). ViPTree: the viral proteomic tree server. *Bioinformatics*, 33(15), 2379-2380. <https://doi.org/10.1093/bioinformatics/btx157>
- Python Software Foundation. (2024). *pickle — Python object serialization*. En *The Python Standard Library* (Versión 3.12). <https://docs.python.org/3/library/pickle.html>
- Ronda, C., Vázquez, M., & López, R. (2003). Los bacteriófagos como herramienta para combatir infecciones en Acuicultura. *AquaTIC*, (18),3-10.
- Roux, S., Enault, F., Hurwitz, B. L., & Sullivan, M. B. (2015). VirSorter: mining viral signal from microbial genomic data. *PeerJ*, 3, e985. <https://doi.org/10.7717/peerj.985>
- Salmond, G., Fineran, P. (2015). A century of the phage: past, present and future. *Nat Rev Microbiol* 13, 777–786. <https://doi.org/10.1038/nrmicro3564>
- Shang, J., Jiang, J., & Sun, Y. (2021). Bacteriophage Claseification for assembled contigs using graph convolutional network. *Bioinformatics*, 37(Supplement_1), i25-i33. <https://doi.org/10.1093/bioinformatics/btab293>

- Siddell, S. G., Smith, D. B., Adriaenssens, E., Alfenas-Zerbini, P., Dutilh, B. E., Garcia, M. L., Junglen, S., Krupovic, M., Kuhn, J. H., Lambert, A. J., Lefkowitz, E. J., Łobocka, M., Mushegian, A. R., Oksanen, H. M., Robertson, D. L., Rubino, L., Sabanadzovic, S., Simmonds, P., Suzuki, N., . . . Zerbini, F. M. (2023). Virus taxonomy and the role of the International Committee on Taxonomy of Viruses (ICTV). *Journal Of General Virology*, 104(5). <https://doi.org/10.1099/jgv.0.001840>
- Sulakvelidze, A., Alavidze, Z., & Morris, J. G., Jr. (2001). Bacteriophage therapy. *Antimicrobial Agents and Chemotherapy*, 45(3), 649–659. <https://doi.org/10.1128/AAC.45.3.649-659.2001>
- Szymanski, P., & Kajdanowicz, T. (2017). A scikit-based Python environment for performing multi-label Classification. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1702.01460>
- Terzian, P., Ndela, E. O., Galiez, C., Lossouarn, J., Bucio, R. E. P., Mom, R., Toussaint, A., Petit, M., & Enault, F. (2021). PHROG: families of prokaryotic virus proteins clustered using remote homology. *NAR Genomics And Bioinformatics*, 3(3). <https://doi.org/10.1093/nargab/lqab067>
- Turner, D., Kropinski, A. M., & Adriaenssens, E. M. (2021b). A Roadmap for Genome-Based Phage Taxonomy. *Viruses*, 13(3), 506. <https://doi.org/10.3390/v13030506>
- Turner, D., Shkoporov, A. N., Lood, C., Millard, A. D., Dutilh, B. E., Alfenas-Zerbini, P., Van Zyl, L. J., Aziz, R. K., Oksanen, H. M., Poranen, M. M., Kropinski, A. M., Barylski, J., Brister, J. R., Chanisvili, N., Edwards, R. A., Enault, F., Gillis, A., Knezevic, P., Krupovic, M., . . . Adriaenssens, E. M. (2023). Abolishment of morphology-based taxa and change to binomial Species names: 2022 taxonomy update of the ICTV bacterial viruses subcommittee. *Archives Of Virology*, 168(2). <https://doi.org/10.1007/s00705-022-05694-2>
- Van Rossum, G., & Drake, F. L. (2009). *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace.
- Vieira, M. F., Duarte, J., Domingues, R., Oliveira, H., & Dias, O. (2025). PhageDPO: A machine-learning based computational framework for identifying phage depolymerases. *Computers In Biology And Medicine*, 188, 109836. <https://doi.org/10.1016/j.combiomed.2025.109836>

8. Anexos

8.1 Selección de herramientas existentes para análisis de fagos

HERRAMIENTA	AUTORES	DESCRIPCIÓN	ACCESO
VirSorter	Roux et al. (2015)	Anotación funcional de genes virales.	https://github.com/simroux/VirSorter
VIBRANT	Kieft et al. (2020)	Anotación funcional de genes virales.	https://github.com/AnantharamanLab/VIBRANT
VICTOR	Meier-Kolthoff y Göker (2017)	Establecer relaciones filogenéticas a partir de genomas completos.	https://ggdc.dsmz.de/victor.php
ViPTree	Nishimura et al. (2017b)	Generar árboles filogenéticos basados en similitudes proteómicas.	https://www.genome.jp/viptree/
taxmyPHAGE	Millard et al. (2024)	Clasificar genomas virales a partir del cálculo detallado de similitud genómica (ANI).	https://millardlab.org/2024/08/13/taxmyphage/
PHROG	Terzian et al. (2021)	Librería de familias de proteínas virales.	https://phrogs.lmge.uca.fr/
Pharokka	Bouras et al. (2022)	Anotación funcional de genes virales.	https://github.com/gbouras13/pharokka
MMseqs2	Steinegger y Söding (2017)	Buscar y agrupar grandes conjuntos de secuencias de proteínas y nucleótidos.	https://github.com/soedinglab/MMseqs2
PHANOTATE	McNair et al. (2019)	Anotación funcional de genes virales.	https://github.com/deprekate/PHANOTATE
Prodigal	Hyatt et al. (2010)	Predicador de genes de genomas procarióticos.	https://github.com/hyatt/Prodigal
tRNAscan-SE 2	Chan y Lowe (2019)	Detección de genes de tRNA.	https://github.com/UCSC-LoweLab/tRNAscan-SE
Aragorn	Laslett (2004)	Detección de genes de tRNA/tmRNA.	https://github.com/TheSEED/aragorn
MinCED	Bland et al. (2007)	Encontrar CRISPRs en genomas y metagenomas.	https://github.com/ctSkennerton/minced
ClaseiPhage	Chibani et al. (2019)	Clasificación taxonómica de fagos mediante detección de genes con HMM y ANN.	No disponible públicamente.
vConTACT	Bolduc et al. (2017)	Agrupamiento de genomas de virus mediante análisis de redes de genes compartidos.	https://bitbucket.org/MAVERICLab/vcontact2/src/master/
PhaGCN	Shang et al. (2021)	Clasificación de fagos mediante redes neuronales.	https://github.com/KennethShang/PhaGCN
PhageScanner	Albin et al. (2024)	Predicción de proteínas virales en genomas y metagenomas.	https://github.com/Dreycey/PhageScanner
PhageDPO	Vieira et al. (2025)	Herramienta para la predicción de depolimerasas (DPOs) codificadas por fagos mediante ML.	https://github.com/mfernandasvieira/phagedpo

8.2. Infografía de la herramienta *PhageTax*

